Лекция 4. Ручное управление памятью

Илья Макаров

ИТМО JB

28 сентября 2021

Санкт-Петербург

Еще раз про указатели

- Указатель — это переменная, хранящая адрес некоторой ячейки памяти.
- Указатели являются типизированными.

```
int i = 3; // переменная типа int
int * p = 0; // указатель на переменную типа int
```

- Нулевому указателю (`nullptr`) не соответствует никакая ячейка памяти.
- Оператор взятия адреса переменной `&`.
- Оператор разыменования `*`.

```
p = &i; // указатель p указывает на переменную i
*p = 10; // изменяется ячейка по адресу p, т.е. i
```

Указатели и const

- Константный указатель — это переменная, хранящая адрес некоторой ячейки памяти, который нельзя изменить.
- Указатель на константу — это переменная, хранящая адрес некоторой ячейки памяти. Данные в этой ячейки нельзя изменить.
- Модификатор — часть типа.

```
int i = 3;
int * const p1 = &i; // константный указатель
int const * p2 = &i; // указатель на константу
const int * p3 = &i; // указатель на константу

p1 = nullptr; // error
*p1 = 10; // ok
p2 = nullptr; // ok
*p2 = 10; // error
```

Связь массивов и указателей

- Указатели позволяют передвигаться по массивам.
- Для этого используется арифметика указателей:

```
int m[10] = {1, 2, 3, 4, 5};
int * p = &m[0]; // адрес начала массива
int * q = &m[9]; // адрес последнего элемента
```

  - `(p + k)` — сдвиг на k ячеек типа `int` вправо.
  - `(p - k)` — сдвиг на k ячеек типа `int` влево.
  - `(q - p)` — количество ячеек между указателями.
  - `p[k]` эквивалентно `*(p + k)`.

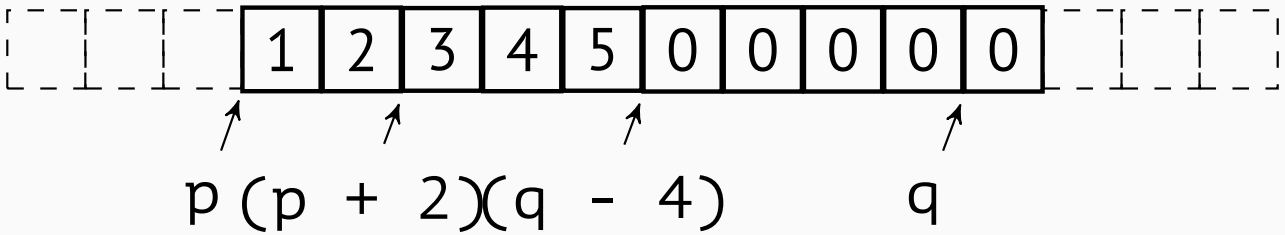

Примеры

Заполнение массива:

```
int m[10] = {}; // изначально заполнен нулями

for (int * p = m ; p <= m + 9; ++p) {
    *p = (p - m) + 1;
} // Массив заполнен числами от 1 до 10
```

Передача массива в функцию:

```
int max_element(int * m, int size) {
    int max = *m;
    for (int i = 1; i < size; ++i) {
        if (m[i] > max) { max = m[i]; }
    }
    return max;
}
```

Два способа передачи массива

```
bool contains(int * m, int size, int value) {
    for (int i = 0; i != size; ++i) {
        if (m[i] == value) { return true; }
    }
    return false;
}
bool contains(int * p, int * q, int value) {
    for (; p != q; ++p) {
        if (*p == value) { return true; }
    }
    return false;
}
```

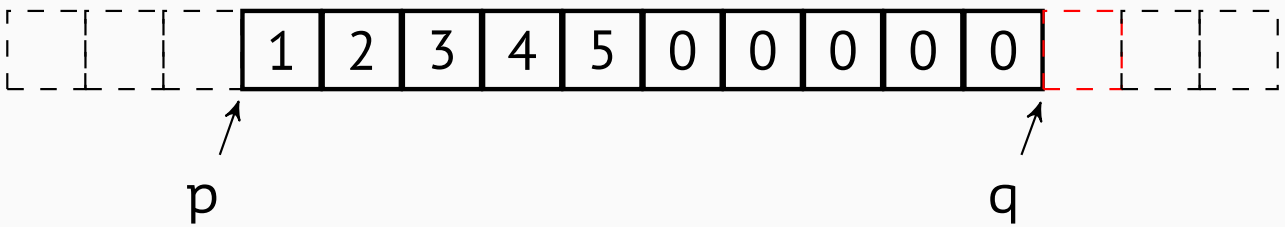

Возврат указателя из функции

Функция для поиска максимума в массиве:

```
int * max_element(int * p, int * q) {
    int * pmax = p;
    for (; p != q; ++p) {
        if (*p > *pmax) { pmax = p; }
    }
    return pmax;
}
```

```
    int m[10] = {...};
    int * pmax = max_element(m, m + 10);
    cout << "Maximum = " << *pmax << endl;
```

Возрат значения через указатель

Функция для поиска максимума в массиве:

```
bool max_element(int * p, int * q, int * res) {
    if (p == q) { return false; }
    *res = *p;
    for (; p != q; ++p) {
        if (*p > *res) { *res = *p; }
    }
    return true;
}
```

```
    int m[10] = {...};
    int max = 0;
    if (max_element(m, m + 10, &max)) {
        cout << "Maximum = " << max << endl;
    }
```

Возрат значения через указатель на указатель

Функция для поиска максимума в массиве:

```
bool max_element(int * p, int * q, int ** res) {
    if (p == q)
        return false;
    *res = p;
    for (; p != q; ++p)
        if (*p > **res)
            *res = p;
    return true;
}
```

```
    int m[10] = {...};
    int * pmax = 0;
    if (max_element(m, m + 10, &pmax))
        cout << "Maximum = " << *pmax << endl;
```

Недостатки указателей

- Использование указателей синтаксически загрязняет код и усложняет его понимание. (Приходится использовать операторы * и &.)
- Указатели могут быть неинициализированными (некорректный код).
- Указатель может быть нулевым (корректный код), а значит указатель нужно проверять на равенство нулю.
- Арифметика указателей может сделать из корректного указателя некорректный (легко промахнуться).
- Тяжелее отследить время жизни указателей.

Еще раз про различия ссылок и указателей

- Ссылка не может быть неинициализированной.

```
int * p; // OK
int & l; // ошибка
```

- У ссылки нет нулевого значения.

```
int * p = 0; // OK
int & l = 0; // ошибка
```

- Ссылку нельзя переприсвоить:

```
int a = 10, b = 20;
int * p = &a; // p указывает на a
p = &b;       // p указывает на b
int & l = a;  // l ссылается на a
l = b;        // a присваивается значение b
```

Еще раз про различия ссылок и указателей

- Нельзя получить адрес ссылки или ссылку на ссылку.

```
int a = 10;
int * p = &a;  // p указывает на a
int ** pp = &p;// pp указывает на переменную p
int & l = a;   // l ссылается на a
int * pl = &l; // pl указывает на переменную a
int && ll = l; // ошибка
```

- Нельзя создавать массивы ссылок.

```
int * mp[10] = {};  // массив указателей на int
int & ml[10] = {};  // ошибка
```

- Для ссылок нет арифметики.

Ссылки и rvalue

Ссылки могут указывать только на lvalue.

```
int a = 10, b = 20;
int m[10] = {1,2,3,4,5,5,4,3,2,1};
int & l1 = a;          // OK
int & l2 = a + b;      // ошибка
int & l3 = *(m + a / 2);          // OK
int & l4 = *(m + a / 2) + 1;      // ошибка
int & l5 = (a + b > 10) ? a : b;  // OK
```

Зачем нужна динамическая память?

- Стек программы ограничен. Он не предназначен для хранения больших объемов данных.

```
// Не умещается на стек
double m[10000000] = {}; // 80 Mb
```

- Время жизни локальных переменных ограничено временем работы функции.
- Динамическая память выделяется в сегменте данных.
- Структура, отвечающая за выделение дополнительной памяти, называется **кучей** (не нужно путать с одноимённой структурой данных).
- Выделение и освобождение памяти *управляется вручную*.

Выделение памяти в стиле C

- Стандартная библиотека `cstdlib` предоставляет четыре функции для управления памятью:

```
void * malloc(size_t size);
void * calloc(size_t nmemb, size_t size);
void * realloc(void * ptr, size_t size);
void free(void * ptr);
```

- `size_t` — специальный целочисленный беззнаковый тип, может вместить в себя размер любого типа в байтах.
- Тип `size_t` используется для указания размеров типов данных, для индексации массивов и пр.
- `void *` — это указатель на нетипизированную память (раньше для этого использовалось `char *`).

Выделение памяти в стиле C

- Функции для управления памятью в стиле C:

```
void * malloc(size_t size);
void * calloc(size_t nmemb, size_t size);
void * realloc(void * ptr, size_t size);
void free(void * ptr);
```

- `malloc` — выделяет область памяти размера $\geq$ `size`. Данные не инициализируются.
- `calloc` — выделяет массив из `nmemb` элементов размера `size`. Данные инициализируются нулём.
- `realloc` — изменяет размер области памяти по указателю `ptr` на `size` (если возможно, то это делается на месте).
- `free` — освобождает область памяти, ранее выделенную одной из функций `malloc`/`calloc`/`realloc`.

Выделение памяти в стиле C

- Для указания размера типа используется оператор `sizeof`.

```
// создание массива из 1000 int
int * m = (int *)malloc(1000 * sizeof(int));
m[10] = 10;

// изменение размера массива до 2000
m = (int *)realloc(m, 2000 * sizeof(int));

// освобождение массива
free(m);

// создание массива нулей
m = (int *)calloc(3000, sizeof(int));
free(m);
m = 0;
```

Выделение памяти в стиле C++

- Язык C++ предоставляет два набора операторов для выделения памяти:
  1. `new` и `delete` — для одиночных значений,
  2. `new []` и `delete []` — для массивов.
- Версия оператора `delete` должна соответствовать версии оператора `new`.

```
// выделение памяти под один int со значением 5
int * m = new int(5);
delete m; // освобождение памяти

// создание массива нулей
m = new int[1000](); // () означает обнуление
delete [] m; // освобождение памяти
```

Типичные проблемы при работе с памятью

- Проблемы производительности: создание переменной на стеке намного “дешевле” выделения для неё динамической памяти.
- Проблема фрагментации: выделение большого количества небольших сегментов способствует фрагментации памяти.
- Утечки памяти:

```
// создание массива из 1000 int
int * m = new int[1000];

// создание массива из 2000 int
m = new int[2000]; // утечка памяти

// Не вызван delete [] m, утечка памяти
```

Типичные проблемы при работе с памятью

- Неправильное освобождение памяти.

```
int * m1 = new int[1000];
delete m1; // должно быть delete [] m1

int * p = new int(0);
free(p); // совмещение функций C++ и C

int * q1 = (int *)malloc(sizeof(int));
free(q1);
free(q1); // двойное удаление

int * q2 = (int *)malloc(sizeof(int));
free(q2);
q2 = 0;   // обнуляем указатель
free(q2); // правильно работает для q2 = 0
```

Многомерные встроенные массивы

- C++ позволяет определять многомерные массивы:

```
int m2d[2][3] = { {1, 2, 3}, {4, 5, 6} };
for( size_t i = 0; i != 2; ++i ) {
    for( size_t j = 0; j != 3; ++j ) {
        cout << m2d[i][j] << ' ';
    }
    cout << endl;
}
```

- Элементы m2d располагаются в памяти “по строчкам”.
- Размерность массивов может быть любой, но на практике редко используют массивы размерности > 4.

```
int m4d[2][3][4][5] = {};
```

Динамические массивы

- Для выделения одномерных динамических массивов обычно используется оператор `new []`.

```
int * m1d = new int[100];
```

- Какой тип должен быть у указателя на двумерный динамический массив?
  - Пусть `m` — указатель на двумерный массив типа `int`.
  - Значит `m[i][j]` имеет тип `int` (точнее `int &`).
  - `m[i][j]` ⇔ `*(m[i] + j)`, т.е. тип `m[i]` — `int *`.
  - аналогично, `m[i]` ⇔ `*(m + i)`, т.е. тип `m` — `int **`.
- Чему соответствует значение `m[i]`?
  Это адрес строки с номером `i`.
- Чему соответствует значение `m`?
  Это адрес массива с указателями на строки.

Двумерные массивы

Давайте рассмотрим создание массива 5×4.

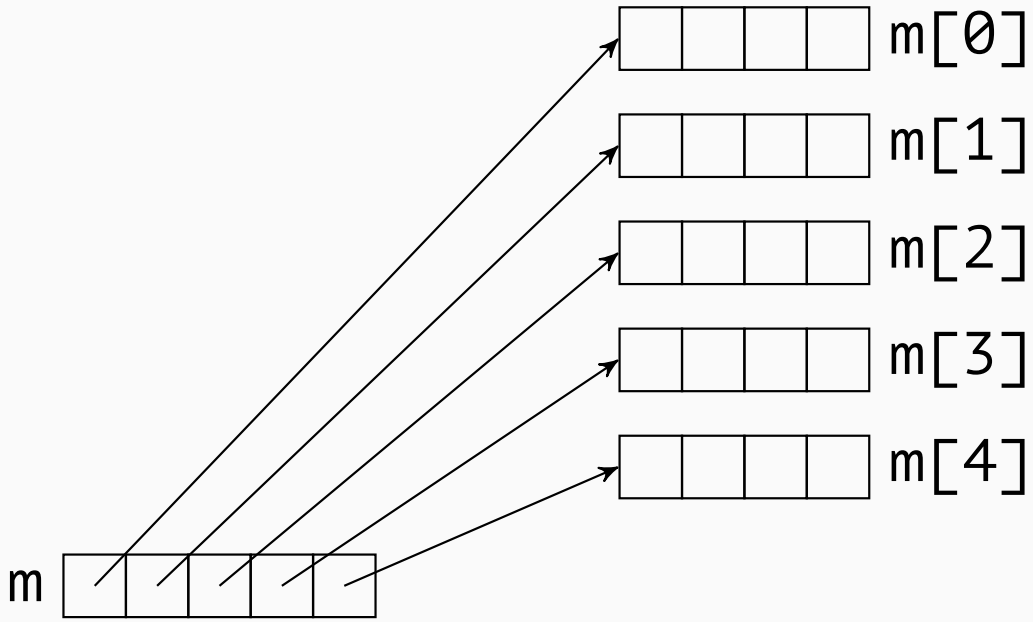


```
int ** m = new int * [5];
for (size_t i = 0; i != 5; ++i)
    m[i] = new int[4];
```

Двумерные массивы

Выделение и освобождение двумерного массива размера $a \times b$.

```
int ** create_array2d(size_t a, size_t b) {
    int ** m = new int *[a];
    for (size_t i = 0; i != a; ++i)
        m[i] = new int[b];
    return m;
}

void free_array2d(int ** m, size_t a, size_t b) {
    for (size_t i = 0; i != a; ++i)
        delete [] m[i];
    delete [] m;
}
```

При создании массива оператор `new` вызывается $(a + 1)$ раз.

Двумерные массивы: эффективная схема

Рассмотрим эффективное создание массива 5×4.

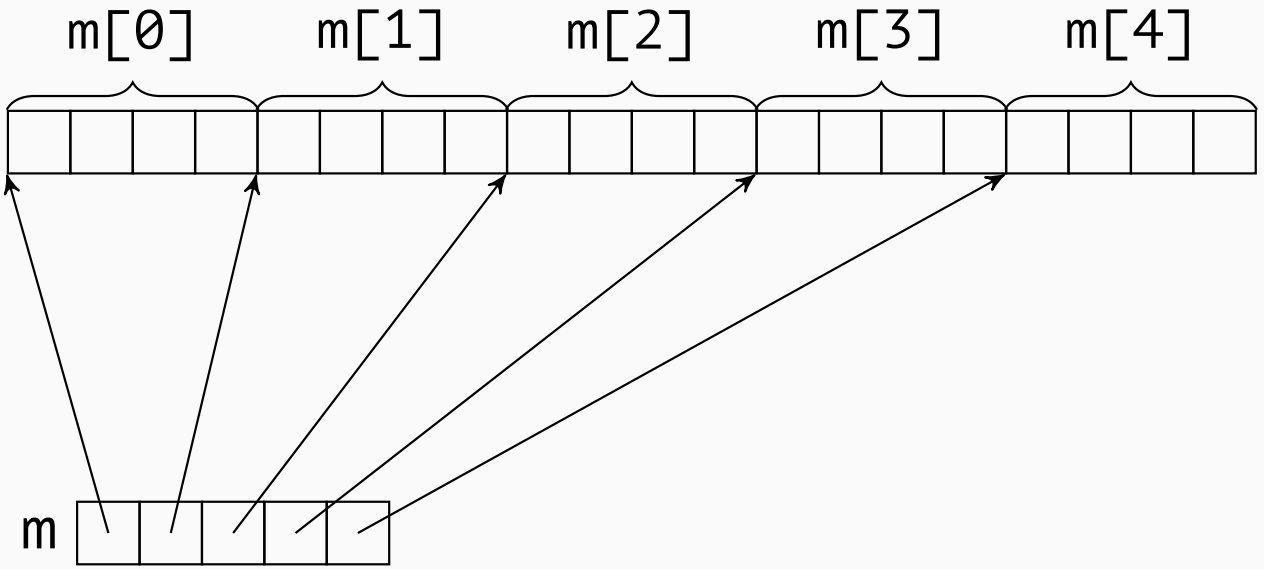


```
int ** m = new int * [5];
m[0] = new int[5 * 4];
for (size_t i = 1; i != 5; ++i)
    m[i] = m[i - 1] + 4;
```

Двумерные массивы: эффективная схема

Эффективное выделение и освобождение двумерного массива размера $a \times b$.

```
int ** create_array2d(size_t a, size_t b) {
    int ** m = new int *[a];
    m[0] = new int[a * b];
    for (size_t i = 1; i != a; ++i)
        m[i] = m[i - 1] + b;
    return m;
}

void free_array2d(int ** m, size_t a, size_t b) {
    delete [] m[0];
    delete [] m;
}
```

При создании массива оператор new вызывается 2 раза.

Умные указатели

1. Идиома RAII (Resource Acquisition Is Initialization): время жизни ресурса связанно с временем жизни объекта.
   - Получение ресурса в конструкторе.
   - Освобождение ресурса в деструкторе.
2. Основные области использования RAII:
   - для управления памятью,
   - для открытия файлов или устройств,
   - для критических секций при параллельном исполнении кода.
3. Умные указатели — объекты, инкапсулирующие владение памятью. Синтаксически ведут себя так же, как и обычные указатели.

Основные стратегии

1. `scoped_ptr` — время жизни объекта ограничено временем жизни умного указателя.
2. `shared_ptr` — разделяемый объект, реализация с подсчётом ссылок.
3. `weak_ptr` — разделяемый объект, реализация с подсчётом ссылок, слабая ссылка (используется вместе с `shared_ptr`).
4. `unique_ptr` — эксклюзивное владение объектом с передачей владения при перемещении.
5. `intrusive_ptr` — разделяемый объект, реализация самим внутри объекта.
6. `linked_ptr` — разделяемый объект, реализация списком указателей.

unique_ptr

- Определен в заголовочном файле <memory>.
- Для передачи и возврата указателей из функции.
- Владение эксклюзивно и передаётся при только при перемещении.

```
void foo(const std::unique_ptr<int> & ptr) {
    std::cout << *ptr;
}
void bar(std::unique_ptr<int> && ptr) {
    std::cout << *ptr;
}
void baz(std::unique_ptr<int> ptr) {
    std::cout << *ptr;
}
```

unique_ptr

```
int main() {
    std::unique_ptr<int> ptr = std::make_unique<int>(10);

    auto & ptr_ref = ptr; // ok
    auto ptr_copy = ptr; // error

    foo(ptr); // ok
    bar(ptr); // error
    bar(std::move(ptr)); // ok
    baz(ptr); // error
    baz(std::move(ptr)); // ok
}
```

shared_ptr

- Для разделяемых объектов.
- Ведётся подсчёт ссылок.
- Нельзя вернуть владение объектом.

```
void foo(const std::shared_ptr<int> & ptr) {
    std::cout << *ptr;
}
void bar(std::shared_ptr<int> && ptr) {
    std::cout << *ptr;
}
void baz(std::shared_ptr<int> ptr) {
    std::cout << *ptr;
}
```

shared_ptr

```
int main() {
    std::shared_ptr<int> ptr = std::make_shared<int>(10);

    auto & ptr_ref = ptr; // no increment
    auto ptr_copy = ptr; // increment

    foo(ptr); // no increment
    bar(ptr); // error
    bar(std::move(ptr)); // no increment
    baz(ptr) // increment
    baz(std::move(ptr)); // no increment
}
```

shared_ptr

```
void foo() {
    // counter == 1
    std::shared_ptr<int> ptr = std::make_shared<int>(10);

    {
        // counter == 2
        auto ptr_copy = ptr;
    } // counter == 1

    {
        // counter == 1
        auto & ptr_ref = ptr;
    } // counter == 1
} // counter == 0
```

shared_ptr

```
void foo() {
    // counter == 1
    std::shared_ptr<int> ptr = std::make_shared<int>(10);

    {
        // counter == 1
        auto ptr_other = std::move(ptr);
    } // counter == 0
}
```

weak_ptr

- Для использования вместе с shared_ptr.
- Слабая ссылка для исключения циклических зависимостей.
- Не владеет объектом.

```
void foo(std::weak_ptr & ptr_weak) {
    if (auto ptr_locked = ptr_weak.lock()) {
        // shared here
    }
}

int main() {
    std::shared_ptr<int> ptr = std::make_shared<int>(10);
    foo(ptr); // implicit cast here
}
```

Умные указатели и const

```
// константный указатель
const auto p1 = std::make_shared<int>(10);
// указатель на константу
auto p2 = std::make_shared<const int>(10);

p1 = nullptr; // error
*p1 = 10; // ok
p2 = nullptr; // ok
*p2 = 10; // error
```

Заключение

- Умные указатели намного удобнее ручного управления памятью.
- Для локальных объектов — `scoped_ptr` (подробнее на семинаре).
- Для разделяемых объектов — `shared_ptr`.
- В сильносвязанных системах рассмотрите возможность использовать `weak_ptr`.
- Используйте `intrusive_ptr` для тех объектов, которые сами управляют своим временем жизни.
- Прочитайте документацию по `shared_ptr` и `unique_ptr`.